

# Kaggle Telco Customer Churn 三种机器学习方法对比实验报告

团队成员：随情英、张三、李四、王五、赵六

2025 年 6 月 10 日

## 1 项目背景与目标

### 1.1 项目背景

对于电信运营商来说，用户流失有很多偶然因素，但通过对用户属性和行为的数字化描述，我们能够在这些数据中挖掘导致用户流失的”蛛丝马迹”。更重要的是，如果能够实时接入这些数据，我们可以借助模型来对未来用户流失风险进行预测，从而及时制定挽留策略，防止用户真实流失情况发生。

### 1.2 机器学习建模目标

在此背景下，实际的算法建模目标有两个：

- 对流失用户进行准确预测
- 找出影响用户流失的重要因子，辅助运营人员调整营销策略或制定用户挽留措施

综合上述两个目标，我们需要模型不仅具备一定的预测能力，还能输出相应的特征重要性排名，并且最好具备一定的可解释性，能够较为明显地阐述特征变化如何影响标签取值变化。基于这些要求，我们优先考虑逻辑回归模型，其线性方程能够提供良好的结果可解释性，同时正则化项也可用于评估特征重要性。此外，我们还对比了决策树和提升方法，以全面评估不同算法的性能。

### 1.3 项目实施阶段

本项目分为三个主要阶段：

#### Stage 1. 业务背景解读与数据探索

在接收任务的第一时间，我们需要对数据及其对应业务的基本背景进行解读。由于数据诞生于特定业务场景，我们尽可能了解数据诞生的基本环境和业务逻辑，准确解读每个

字段的含义。随后进行数据探索，包括数据分布检验、数据正确性校验、数据质量检验、训练集/测试集规律一致性检验等。

### Stage 2. 数据预处理与特征工程

这一阶段包括数据清洗和特征工程。数据清洗主要聚焦于提升数据集质量，包括缺失值、异常值、重复值处理，以及数据字段类型调整等；特征工程则调整特征基本结构，使数据集规律更容易被模型识别，如特征衍生、特殊类型字段处理等。

### Stage 3. 算法建模与模型调优

最终的建模环节包括算法训练和参数调优。我们尝试了多种模型、调参方法以及模型对比，并根据模型输出结果调整数据预处理和特征工程相关方法，以获得最优的预测性能。

## 1.4 数据集说明

本实验选用 Kaggle Telco Customer Churn 数据集。该数据集包含 7043 条客户记录，每条记录包含 21 个特征，目标变量为客户是否流失 (Churn)，属于二分类问题。数据类型包括数值型和分类型，适合多种机器学习方法。

### 1.4.1 数据集详情

该数据集模拟了电信公司的客户信息及其流失状态，包含以下主要特征：

- **个人信息类特征：**性别 (gender)、年龄 (SeniorCitizen)、伴侣状态 (Partner)、是否有抚养人 (Dependents)
- **账户信息类特征：**账户时长 (tenure)、合同类型 (Contract)、付款方式 (Payment-Method)、无纸化账单 (PaperlessBilling)、月度费用 (MonthlyCharges)、总费用 (TotalCharges)
- **服务信息类特征：**电话服务 (PhoneService)、多线电话 (MultipleLines)、互联网服务 (InternetService)、在线安全 (OnlineSecurity)、在线备份 (OnlineBackup)、设备保护 (DeviceProtection)、技术支持 (TechSupport)、流媒体电视 (StreamingTV)、流媒体电影 (StreamingMovies)

### 1.4.2 数据集特点

- **样本分布：**流失客户占比约 26.5% (1869 人)，非流失客户占比约 73.5% (5174 人)，存在一定的类别不平衡
- **特征类型：**包含 17 个分类特征和 4 个数值特征
- **数据质量：**TotalCharges 列存在 11 条缺失记录，其余特征数据完整

- **特征相关性：**月费用 (MonthlyCharges) 与多项服务选择存在较强相关性，总费用 (TotalCharges) 与账户时长 (tenure) 和月费用呈正相关

该数据集特别适合客户流失预测研究，因为它包含了多种可能影响客户决策的因素，既有客户自身的特征，也有服务相关的特征，能够较为全面地反映现实业务场景中客户流失的复杂原因。

## 2 团队分工

### 2.1 数据集说明

本实验选用 Kaggle Telco Customer Churn 数据集。该数据集包含 7043 条客户记录，每条记录包含 21 个特征（如性别、合同类型、服务类型、月费用、总费用等），目标变量为客户是否流失 (Churn)，属于二分类问题。数据类型包括数值型和分类型，适合多种机器学习方法。

### 2.2 算法简介

本实验对比了三种经典机器学习算法在该数据集上的表现：

- **Logistic Regression (逻辑回归)：**适用于二分类问题，能够输出客户流失的概率，易于解释。
- **Decision Tree (决策树)：**通过特征的条件分裂构建树结构，适合处理非线性关系，易于解释。
- **Boosting (提升方法，采用 AdaBoost)：**通过集成多个弱分类器（如决策树），提升整体分类性能，适合处理复杂关系。

### 2.3 团队分工

- 数据预处理与代码实现：随情英
- 模型训练与调参：张三
- 实验结果整理与可视化：李四
- 实验报告撰写与校对：王五

## 3 三种方法的测试与比较

### 3.1 实验设置

- 训练集：数据集的 80%（约 5634 条记录）
- 测试集：数据集的 20%（约 1409 条记录）
- 所有分类型特征进行独热编码，数值型特征归一化
- 评估指标：准确率 (accuracy)、AUC、分类报告 (precision、recall、f1-score)、混淆矩阵、训练时间

### 3.2 实验结果总览

模型	测试准确率	AUC	训练时间 (秒)
Logistic Regression	0.8000	0.8350	0.01
Decision Tree	0.7220	0.6348	0.02
Boosting	0.7305	0.7523	1.13

### 3.3 可视化对比




图 1: 三种模型准确率对比




图 2: 三种模型 ROC 曲线及 AUC 对比

### 3.4 详细分类报告与混淆矩阵

#### Logistic Regression

训练时间：0.01 秒

准确率：0.8000

AUC: 0.8350

分类报告：

	precision	recall	f1-score	support
0	0.84	0.89	0.87	518
1	0.65	0.54	0.59	187
accuracy			0.80	705
macro avg	0.75	0.72	0.73	705
weighted avg	0.79	0.80	0.79	705

混淆矩阵：

```
[[463  55]
 [ 86 101]]
```

#### Decision Tree

训练时间：0.02 秒

准确率：0.7220

AUC: 0.6348

分类报告：

	precision	recall	f1-score	support
0	0.80	0.82	0.81	518
1	0.47	0.45	0.46	187
accuracy			0.72	705
macro avg	0.64	0.63	0.64	705
weighted avg	0.72	0.72	0.72	705

混淆矩阵：

```
[[425  93]
 [103  84]]
```

### Boosting (AdaBoost)

训练时间： 1.13 秒

准确率： 0.7305

AUC: 0.7523

分类报告：

	precision	recall	f1-score	support
0	0.82	0.82	0.82	518
1	0.49	0.49	0.49	187
accuracy			0.73	705
macro avg	0.65	0.65	0.65	705
weighted avg	0.73	0.73	0.73	705

混淆矩阵：

```
[[423  95]
 [ 95  92]]
```

## 3.5 分析与讨论

- 逻辑回归在该数据集上表现最好，准确率和 AUC 均最高，且训练速度极快，适合实际业务部署。
- 决策树模型训练速度快，但泛化能力有限，AUC 较低，容易过拟合。

- Boosting 方法（AdaBoost）在准确率和 AUC 上均优于单棵决策树，提升了模型的整体性能，但训练时间略长。
- 三种方法的混淆矩阵和分类报告显示，所有模型对“非流失”客户的识别能力较强，对“流失”客户的召回率和精确率相对较低，后续可考虑进一步优化模型或采用更复杂的集成方法。

## 4 总结

本实验对比了三种机器学习方法在 Kaggle Telco Customer Churn 数据集上的表现。逻辑回归表现最佳，Boosting 方法次之，决策树表现一般。实验结果表明，针对结构化二分类数据，线性方法和集成方法均能取得较好效果。后续可尝试更多特征工程和模型融合进一步提升性能。